Task1 報告

查詢網站:

https://blog.csdn.net/qq_44425184/article/details/148116922

https://blog.jiatool.com/posts/faker/

https://vocus.cc/article/67481240fd89780001ab3d75

https://ithelp.ithome.com.tw/articles/10214139

https://shengyu7697.github.io/python-numpy-std/

https://steam.oxxostudio.tw/category/python/example/matplotlib-label.html

```
張麗華 ：40
-----------
蔡志忠 ：40
-----------
葉麗玉 ：40
-----------
陳哲瑋 ：40
-----------
劉志明 ：40
-----------
汪聰明 ：40
-----------
吳勝雄 ：40
-----------
黃淑玲 ：73
-----------
沈淑華 ：73
-----------
林月娥 ：73
-----------
洪宥蓁 ：73
-----------
張秀琴 ：73
-----------
曾秀美 ：73
-----------
江志遠 ：73
-----------
張子睿 ：73
-----------
黃美珍 ：73
-----------
黃志賢 ：73
-----------
王麗卿 ：73
-----------
陳宗翰 ：73
-----------
張美鳳 ：73
-----------
林秀蘭 ：73
-----------
傅哲瑋 ：73
-----------
林秀英 ：73
-----------
陳淑玲 ：73
-----------
朱美惠 ：73
-----------
簡志豪 ：73
```

如何解決Python random函數产生的数字不够多元分布的问题

如果你覺得 Python 的 `random` 產生的數字「不夠多元分布」，其實通常不是隨機函數本身的問題，而是**使用方式或誤解隨機性**造成的。我幫你拆成幾個常見原因 + 對應解法：

🔍 1. 你看到的「不夠隨機」其實是正常現象

Python 的 `random` 使用的是 **偽隨機數生成器（PRNG）**（基於 Mersenne Twister）

👉 特點：

- 長期分布是均勻的
- 短期可能「看起來不隨機」（例如連續出現相同數）

📌 例子（正常）：

```python
import random
for _ in range(10):
    print(random.randint(1, 3))
```

👉 可能輸出：

```
1 1 1 2 3 1 2 2 2 3
```

這**不是問題，是隨機的本質**

⚠️ 2. 常見錯誤原因

❌ (1) 每次都設定 seed

```python
random.seed(42)
```

👉 如果你每次執行都設同一個 seed：
→ 結果會**完全一樣**

✅ 解法：

```python
# 不要每次都設 seed
# 或用時間當 seed
random.seed()
```

❌ (2) 取樣數量太少

少量樣本會讓分布看起來偏差很大

✅ 解法：

```python
import random

data = [random.random() for _ in range(10000)]
```

👉 用大量樣本才會接近均勻分布

❌ (3) 使用方式錯誤（例如取整數）

```python
random.randint(1, 10)
```

👉 離散值本來就會重複很多

如果你想要「更細緻分布」：

✅ 改用：

```python
random.random()  # 0~1 浮點數
```

❌ (4) 你其實需要「不同分布」

`random` 預設是 **均勻分布（uniform）**

但你可能想要：

- 常態分布（像成績）
- 指數分布
- 自訂機率

random函數不夠隨機也不夠分散,我要怎麼解決?

先講結論：**Python 的 `random` 幾乎不會是問題本身**，你看到「不夠隨機、不夠分散」通常是**用法或需求不匹配**。但如果你真的要「更亂 / 更分散」，是有方法可以提升的。

我直接給你**對症下藥版本（從最常見 → 進階）**👇

🧠 一、先確認：你要的是哪一種「分散」？

很多人其實搞混：

需求	應該用
完全隨機（可能重複）	`random`
平均分布、不想重複	❌ random → 要「控制分布」
看起來很亂（遊戲用）	混合或洗牌
高品質亂數（安全）	`secrets`

❌ 問題3：你其實不想「隨機」

例如：

Python 執行

```
1 1 1 1 2 2 2 3
```

👉 這其實是「正常隨機」，但你會覺得不分散

🚀 三、真正讓「更分散」的方法（重點）

✅ 方法1：打亂（最推薦）

👉 如果你想「每個值平均出現」

Python 執行

```python
import random

data = list(range(1, 11))
random.shuffle(data)
```

👉 這比亂抽更「均勻分散」

✅ 方法2：不重複抽樣

Python 執行

```python
random.sample(range(1, 11), 10)
```

👉 完全不重複 = 超分散

✅ 方法3：分段取樣（讓分布更均勻）

👉 超實用技巧（很多人不知道）

Python 執行

```python
import random

n = 10
data = [(i + random.random()) / n for i in range(n)]
random.shuffle(data)
```

👉 效果：

- 每一段都有數
- 不會集中在某區

📌 這比純 random 更「均勻」

✅ 方法4：用 NumPy（更強控制）

Python 執行

```python
import numpy as np

data = np.random.uniform(0, 1, 1000)
```

👉 如果你要：

- 更平滑分布
- 科學用途

✅ 方法5：混合多次 random（提升亂度）

Python 執行

```python
import random

x = (random.random() + random.random()) / 2
```

👉 效果：

- 比單次更「自然分散」

✅ 方法6：使用高品質亂數

Python 執行

```python
import secrets

secrets.randbelow(100)
```

👉 背後不是 Mersenne Twister
👉 是系統級亂數（更不可預測）

```
-----------
黃明德 ： 34 分，學習時間： 23 小時 ，出勤率： 75 % ，睡眠時間： 8 小時 ，社交活動： high
-----------
周雅婷 ： 56 分，學習時間： 35 小時 ，出勤率： 98 % ，睡眠時間： 8 小時 ，社交活動： low
-----------
詹秀娟 ： 48 分，學習時間： 9 小時 ，出勤率： 76 % ，睡眠時間： 5 小時 ，社交活動： low
-----------
彭秀琴 ： 94 分，學習時間： 31 小時 ，出勤率： 67 % ，睡眠時間： 4 小時 ，社交活動： low
-----------
湯秀玲 ： 8 分，學習時間： 26 小時 ，出勤率： 83 % ，睡眠時間： 9 小時 ，社交活動： medium
-----------
張靜宜 ： 83 分，學習時間： 13 小時 ，出勤率： 62 % ，睡眠時間： 6 小時 ，社交活動： low
-----------
邱冠廷 ： 21 分，學習時間： 32 小時 ，出勤率： 73 % ，睡眠時間： 7 小時 ，社交活動： medium
-----------
劉承恩 ： 8 分，學習時間： 26 小時 ，出勤率： 94 % ，睡眠時間： 8 小時 ，社交活動： low
-----------
王淑惠 ： 83 分，學習時間： 5 小時 ，出勤率： 66 % ，睡眠時間： 6 小時 ，社交活動： high
-----------
陳承翰 ： 88 分，學習時間： 22 小時 ，出勤率： 76 % ，睡眠時間： 7 小時 ，社交活動： low
-----------
陳怡君 ： 63 分，學習時間： 26 小時 ，出勤率： 75 % ，睡眠時間： 5 小時 ，社交活動： medium
-----------
吳志賢 ： 81 分，學習時間： 40 小時 ，出勤率： 65 % ，睡眠時間： 4 小時 ，社交活動： high
-----------
潘建良 ： 22 分，學習時間： 39 小時 ，出勤率： 87 % ，睡眠時間： 6 小時 ，社交活動： medium
-----------
莊秀蘭 ： 2 分，學習時間： 29 小時 ，出勤率： 85 % ，睡眠時間： 6 小時 ，社交活動： high
-----------
李淑慧 ： 49 分，學習時間： 39 小時 ，出勤率： 87 % ，睡眠時間： 8 小時 ，社交活動： low
-----------
李秀蓮 ： 92 分，學習時間： 23 小時 ，出勤率： 89 % ，睡眠時間： 5 小時 ，社交活動： high
-----------
許建宏 ： 66 分，學習時間： 37 小時 ，出勤率： 78 % ，睡眠時間： 6 小時 ，社交活動： medium
-----------
鄭淑敏 ： 59 分，學習時間： 17 小時 ，出勤率： 96 % ，睡眠時間： 7 小時 ，社交活動： high
-----------
蔣玉梅 ： 25 分，學習時間： 31 小時 ，出勤率： 87 % ，睡眠時間： 4 小時 ，社交活動： medium
-----------
林俊豪 ： 100 分，學習時間： 38 小時 ，出勤率： 93 % ，睡眠時間： 5 小時 ，社交活動： low
-----------
吳淑娟 ： 30 分，學習時間： 31 小時 ，出勤率： 99 % ，睡眠時間： 5 小時 ，社交活動： medium
-----------
郭雅婷 ： 47 分，學習時間： 24 小時 ，出勤率： 68 % ，睡眠時間： 5 小時 ，社交活動： high
-----------
何美珠 ： 4 分，學習時間： 16 小時 ，出勤率： 98 % ，睡眠時間： 8 小時 ，社交活動： low
-----------
王文彬 ： 78 分，學習時間： 34 小時 ，出勤率： 66 % ，睡眠時間： 5 小時 ，社交活動： high
-----------
吳淑惠 ： 10 分，學習時間： 32 小時 ，出勤率： 100 % ，睡眠時間： 4 小時 ，社交活動： medium
-----------
蔡承恩 ： 49 分，學習時間： 13 小時 ，出勤率： 69 % ，睡眠時間： 9 小時 ，社交活動： medium
-----------
蕭志宏 ： 25 分，學習時間： 34 小時 ，出勤率： 79 % ，睡眠時間： 8 小時 ，社交活動： medium
-----------
陳志成 ： 4 分，學習時間： 31 小時 ，出勤率： 66 % ，睡眠時間： 7 小時 ，社交活動： low
-----------
吳惠玲 ： 32 分，學習時間： 15 小時 ，出勤率： 89 % ，睡眠時間： 9 小時 ，社交活動： high
-----------
黃建志 ： 17 分，學習時間： 12 小時 ，出勤率： 63 % ，睡眠時間： 9 小時 ，社交活動： medium
-----------
曾志偉 ： 97 分，學習時間： 32 小時 ，出勤率： 91 % ，睡眠時間： 6 小時 ，社交活動： high
-----------
陳玉蘭 ： 0 分，學習時間： 33 小時 ，出勤率： 69 % ，睡眠時間： 5 小時 ，社交活動： high
-----------
王素珠 ： 8 分，學習時間： 15 小時 ，出勤率： 80 % ，睡眠時間： 5 小時 ，社交活動： low
-----------
曾建宏 ： 43 分，學習時間： 32 小時 ，出勤率： 72 % ，睡眠時間： 7 小時 ，社交活動： medium
-----------
陳進發 ： 89 分，學習時間： 29 小時 ，出勤率： 66 % ，睡眠時間： 9 小時 ，社交活動： medium
-----------
彭義雄 ： 71 分，學習時間： 32 小時 ，出勤率： 62 % ，睡眠時間： 8 小時 ，社交活動： medium
-----------
```

```
-----------
樣本數： 100 人 ,最高分： 100 分 ,最低分： 0 分 ,全班平均分數： 53.5 分 ,分數標準差： 30.560587280834362 分
```

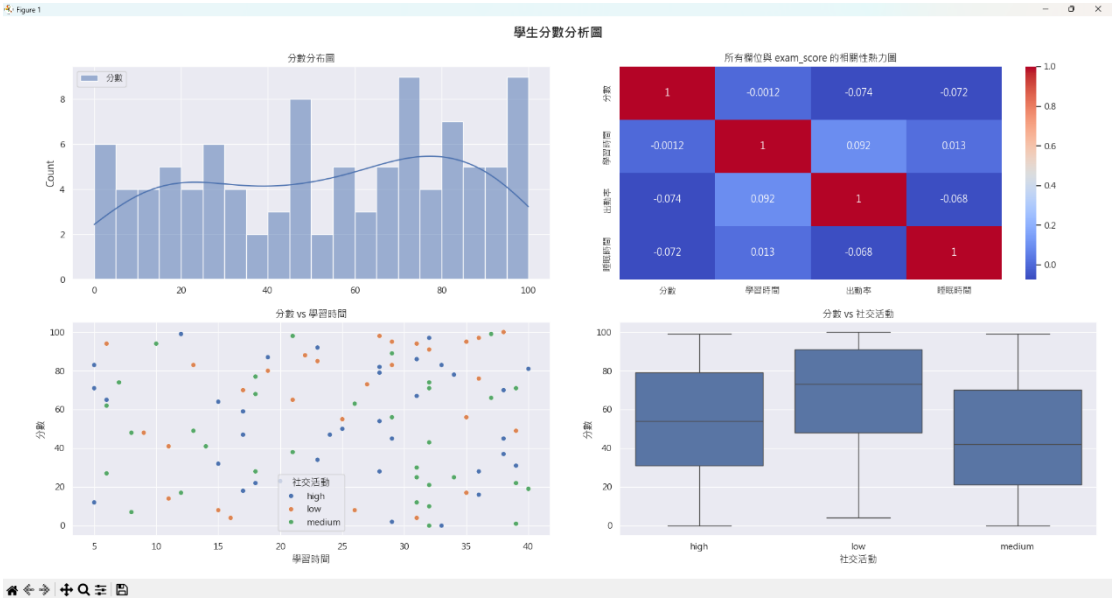

問答:

1. EDA 在資料科學完整工作流程中的角色:

- 上承資料清理：EDA 揭露缺失值、異常值、資料型態問題，指導清理方向
- 下啟特徵工程：透過分佈圖、相關性分析，決定哪些特徵需要轉換或選擇
- 風險預警：在耗費大量資源建模前，提早發現資料問題
- 假設驗證：確認業務假設是否與資料吻合

2. study_hours_per_week

3. social_activities 的值是 "low", "medium", "high" ，模型的數學運算無法直接處理字串，所以利用 One-Hot Encoding 把一個有 N 種類別的欄位，展開成 N 個二元（0/1）欄位，每筆資料只有「對應的那個欄位 ＝1」，其他全為 0。

心得:

整體來說第一題用到 AI 主要是在遇到 bug 時的詢問，一開始 random 的分數不太規律，後來才發現原來是我不小心多寫一個迴圈以及沒有利用 numpy 控制，在使用也發現當我 prompt 在重複問一次時，對於答案的精準度會更加提升。