(一) 使用 prompt (左至右)

synthetic_ehr_500.xlsx

XLSX

"請讀取 synthetic_ehr_500.xlsx，做完整 EDA：1. 顯示 shape、dtypes、前 5 筆 2. 計算各欄位缺失值數量與比例，繪製水平長條圖 3. 繪製 length_of_stay_days 的直方圖（bins=20）+ KDE 曲線 4. 計算所有數值型特徵與 length_of_stay_days 的相關係數，繪製熱力圖 5. 用 boxplot 比較不同 primary_dx_group 的住院天數分布（按中位數由高到低排序）給我提示 我要用python可以跑

Viewed a file, ran a command >

現在我有了資料結構，來生成完整的 EDA Python 腳本：

Ran 2 commands, created a file >

腳本跑通了！中文字型 warning 是在 Linux 環境的正常現象，不影響功能，我在腳本裡加一個字型修正提示。

Presented file >

✅ 腳本已驗證可執行，以下是使用說明：

執行方式

bash

```bash
# 1. 安裝依賴
pip install pandas openpyxl matplotlib seaborn scipy

# 2. 把 xlsx 和 py 放在同一資料夾，執行
python eda_synthetic_ehr.py
```

> 修改第 23 行的 `FILE` 路徑為你的實際位置即可。

腳本涵蓋的 5 個分析

#	內容	輸出
1	shape、dtypes、head(5)	console 印出
2	缺失值數量＋比例 → 水平長條圖	`plot_02_missing.png`
3	LOS 直方圖（bins=20）＋KDE＋mean/median 線	`plot_03_los_hist_kde.png`
4	數值特徵相關矩陣熱力圖（左側額外顯示與 LOS 的單欄 bar）	`plot_04_correlation_heatmap.png`
5	Boxplot 各診斷群 LOS（按中位數高→低）＋散點 jitter	`plot_05_boxplot_dx_los.png`

⚠️ 如果標題出現亂碼（Linux 上的中文字型問題）

在腳本開頭加這幾行：

python

```python
import matplotlib.font_manager as fm
# 如已安裝 noto-cjk，用以下設定；否則把標題改成英文即可
plt.rcParams["font.family"] = ["Noto Sans CJK TC", "DejaVu Sans"]
```

我是在windows環境跑

以下是針對 Windows 環境優化的版本，主要修正中文字型問題：

Viewed a file, edited a file, read a file >

已更新完成！Windows 上的關鍵修改有三點：

1. 自動偵測中文字型，依序嘗試：
   - `Microsoft JhengHei`（微軟正黑體，繁體）
   - `Microsoft YaHei`（微軟雅黑，簡體）
   - `SimHei`、`DFKai-SB` 等備選
2. 修正負號顯示 — 加了 `axes.unicode_minus: False`，避免負號變成方塊。
3. 字型同步套用到 seaborn，確保標題跟軸標籤一致。

執行時如果看到這行就代表正常：

```
✓ 使用中文字型: Microsoft JhengHei
```

```python
"""
EDA for synthetic_ehr_500.xlsx
執行方式: python eda_synthetic_ehr.py
需要安裝: pip install pandas openpyxl matplotlib seaborn scipy
"""

import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import matplotlib.ticker as mticker
import matplotlib.font_manager as fm
import seaborn as sns
from scipy.stats import gaussian_kde

# ── Windows 中文字型設定 ──────────────────────────
# 依序嘗試常見 Windows 中文字型，找到第一個可用的
_cjk_candidates = ["Microsoft JhengHei", "Microsoft YaHei",
                   "DFKai-SB", "SimHei", "Arial Unicode MS"]
_available = {f.name for f in fm.fontManager.ttflist}
_cjk_font = next((f for f in _cjk_candidates if f in _available), None)

if _cjk_font:
    plt.rcParams["font.family"] = [_cjk_font, "DejaVu Sans"]
    print(f"✓ 使用中文字型: {_cjk_font}")
else:
    print("⚠ 未找到中文字型，標題/軸標籤將改用英文顯示")

plt.rcParams.update({"font.size": 11, "axes.titlesize": 13,
                     "axes.labelsize": 11, "figure.dpi": 150,
                     "axes.unicode_minus": False})  # 修正負號顯示

# ── 全域樣式 ──────────────────────────────────────
sns.set_theme(style="whitegrid", palette="muted",
              rc={"font.family": plt.rcParams["font.family"]})

FILE = "synthetic_ehr_500.xlsx"   # ← 修改成你的實際路徑
```

(二) 模型評估報告表格

模型	Train MSE	Test MSE	Train MAE	Test MAE	Test R^2
Linear Regression	1.808	2.85	1.015	1.2344	0.432
Random Forest	1.29377	2.43	0.83	1.083	0.52
XGBoost	0.015	2.29	0.0935	1.067	0.543

```
模型評估報告
==================================================================
                   Train MSE  Test MSE Train MAE  Test MAE   Test R²
Linear Regression   1.808084  2.849405  1.014701  1.234427  0.432389
Random Forest        1.29377  2.430075  0.805673   1.08287  0.515921
XGBoost             0.015396   2.29134  0.093554  1.067114  0.543558
```

(三) 問答

20. 為什麼要對類別型特徵做 One-Hot Encoding？不做會有什麼問題？

A: One-Hot Encoding 將每個類別轉為獨立的 0/1 二元欄位，讓電腦看得懂好學習，不做轉換將導致預測偏差，模型表現下降。

21. StandardScaler 的目的是什麼？為什麼只對訓練集 fit，再 transform 測試集？

A: 將不同數值限制在 0 跟 1 可以讓收斂速度加快，學習效果更好，如果也對測試集 fit 就好像偷看答案，沒有意義，所以要將其再 transform 測試集。

22. 特徵重要性 vs 相關係數：Step 1 中相關係數最高的特徵，是否也出現在 Feature Importance 前幾名？若有差異，可能的原因？

A: 部分重疊，但不完全一致，可能原因或許是，相關係數只看線性關係某特徵**可能與 LOSS 是非線性關係，相關係數低但 Feature Importance。**

- **Feature Importance: 每個特徵對預測結果的貢獻程度**

23. 特徵選擇實驗（Slide P.19）：刪除重要性最低的 5 個特徵後重新訓練，模型效能如何變化？

A: 整體效能不會變化太多，因為重要性特徵本來就比較稀疏。

24. MSE/MAE 臨床解讀：你的最佳模型 Test MAE 是多少天？若病患實際住院 7 天但模型預 測 4 天，這個誤差在臨床上代表什麼？

A: 最佳模型是 XGBoost，Test MAE = 1.041 天，且誤差在臨床上代表可能是，床位調度提、人力不足、保險給付

25. 完整管線回顧（Slide P.11）：完整說明你走過的「資料科學管線」每個步驟，對應 Slide 的哪個概念。

A: Task1 對應 p.11 的資料蒐集、清洗與分析

Task2 對應 p.11 的資料蒐集、清洗與分析

Task3 對應 p.11 的資料蒐集、清洗與分析、模型訓練與評估

Task4 對應 p.11 的資料蒐集、清洗與分析、特徵工程、模型訓練與評估
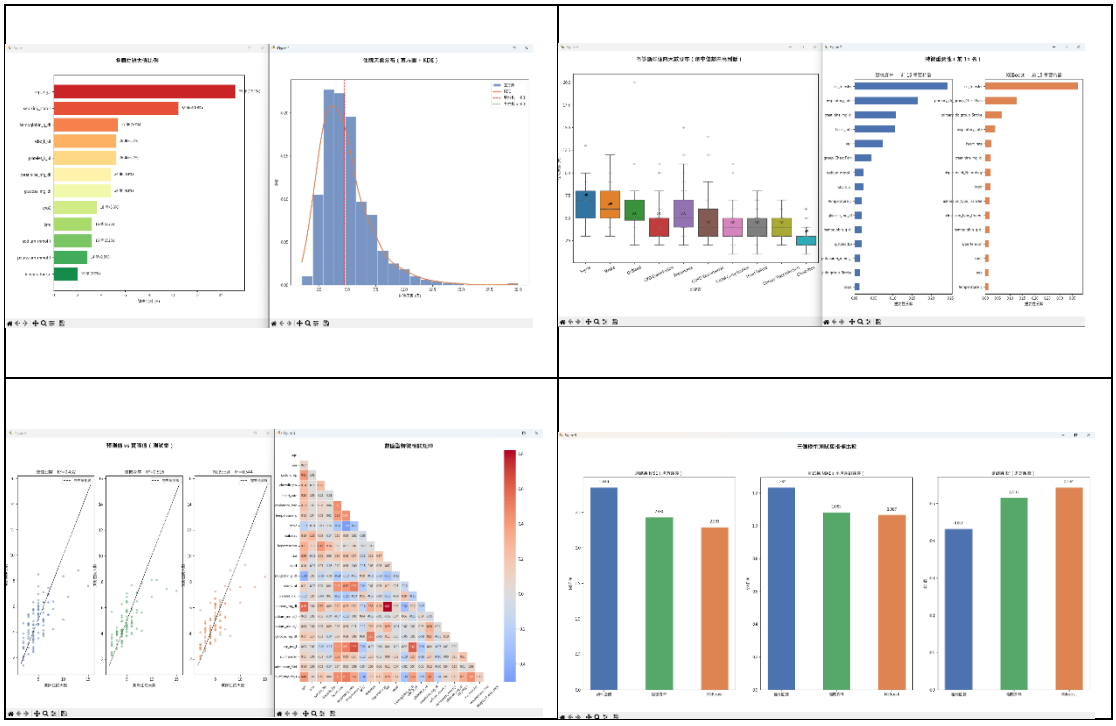
(四) 圖表結果